

Previsão de Tarifa de Rideshare em Nova York

Pipeline Big Data end-to-end para previsão de tarifa com Spark e três modelos de regressão

Guilherme Waizbart · João Victor · Renan Vizoto





Problema e Motivação

- **"Quanto vai custar minha corrida de Uber ou Lyft em NYC?"**
 - A tarifa NÃO é determinística: varia por distância, horário, zona, operadora e demanda (surge pricing)
- **Por que prever passenger_fare e não driver_pay?**
 - driver_pay é calculado por fórmula regulatória (TLC Local Law 150/2018) → $R^2 > 0.97$ trivialmente
 - passenger_fare carrega sinal de mercado real (surge pricing, zona, demanda)
- **Valor de negócio**
 - Transparência para o passageiro · Planejamento para motoristas · Modelagem de surge pricing



Dataset — NYC Rideshare Raw Data (Kaggle)

Coluna	Tipo	Descrição
passenger_fare	float	TARGET: tarifa base (USD)
trip_length	float	Distância em milhas
total_ride_time	int	Duração em segundos
hour_of_day	int	Hora do embarque (0–23)
business	string	Operadora (Uber ou Lyft)
date	date	Data do embarque
hourly_rate/dollars_per_mile	—	Excluídas: leakage do target




Pipeline de Dados e Pré-processamento

Regras de limpeza

- Remoção de zonas inválidas
- Remoção de espera negativa
 - Erro em timestamp
- Filtro de outliers e filtragem de cauda longa




Filtro por percentil 0.1%-99.9% remove a cauda extrema sem distorcer o corpo da distribuicao




Pré-processamento: Validação e Consistência


Velocidade média em Manhattan ~7 mph; corte por percentil se calibra a NYC, evitando cutoffs fixos arbitrários



Limpeza consistente entre meses (~94-95% mantido) — sem viés temporal de qualidade



Share das features booleanas geradas — base para entender importancia preditiva








Feature Engineering: 14 numéricas + 4 categóricas = 18 features



Feature	Como gerada	Por que importa
speed_mph	$\text{trip_length} / (\text{total_ride_time} / 3600)$	Proxy de congestionamento
is_rush_hour	hora 7–9 ou 16–19	Surge pricing em horário de pico
is_late_night	hora ≥ 22 ou ≤ 4	Tarifa noturna mais alta
pickup_airport	zona IN (1, 132, 138)	EWJ/JFK/LGA, tarifa fixa/menor
same_borough	$\text{pu_borough} == \text{do_borough}$	Corridas curtas intra-bairro
pickup_dow	DAYOFWEEK(date)	Variação fim de semana vs semana
pu_borough/do_borough	JOIN taxi_zone_lookup.csv	Variação geográfica de preço



EDA: Volume e Distribuição da Tarifa





EDA: Padrões Temporais de Tarifa







EDA: Operadoras e Variação Geográfica

Distribuição da tarifa por operadora — Uber e Lyft com perfis similares no medio, diferentes na cauda




Variação geografica de tarifa e volume — justifica pu_borough/do_borough como features categoricas



EDA: Correlação Distância x Tarifa e Fluxo entre Bairros

Tarifa x distancia (corr=0.863) — relacao forte mas nao linear; surge e tarifas fixas de aeroporto criam disperso vertical



Fluxo de viagens por borough (OD) — valores em milhares de corridas



Modelo 1: Regressão Linear (Spark MLlib)

0.806

R^2

\$9.07

RMSE

\$5.76



MAE

229 s

Tempo treino

56.3M linhas


Dados de treino







Regressão Linear: Análise de Erros Estratificada

Manhattan tem o maior erro absoluto (corridas mais variáveis); Bronx, o menor (rotas mais homogêneas)



Erro cresce ~3x do bucket 0-2mi para 10+mi: surge pricing e tarifas fixas de aeroporto são não-lineares





Modelo 2: Árvore de Decisão (Spark MLlib)

0.813

R^2

\$8.91

RMSE

\$5.13



MAE

436 s

Tempo treino

56.3M linhas







Dados de treino





Árvore de Decisão: Análise de Erros Estratificada

Decision Tree mantém padrão: Manhattan/Queens com erro maior, Bronx/SI com menor



Modelo 3: Rede Neural (PyTorch)

0.815

R^2

\$8.91

RMSE

\$4.94




MAE

555 s

Tempo treino

1.28M linhas

Dados de treino*







Rede Neural: Treinamento e Análise de Erros

NN com MAE menor que LR e DT em quase todos os boroughs


RMSE por borough - NN




MAE por borough - NN




RMSE por bucket de distancia - NN




MAE por bucket de distancia - NN



Resíduo por bucket de distancia x operadora - NN



Erro agregado por operadora - NN





Comparativo Final dos Modelos

Modelo	R ²	RMSE	MAE	Treino	Dados
Linear Regression (MLlib)	0.806	\$9.07	\$5.76	229s	56.3M
Decision Tree depth=8 (MLlib)	0.813	\$8.91	\$5.13	436s	56.3M
Neural Network ★ (PyTorch)	0.815	\$8.91	\$4.94	555s	1.28M

Distância	RMSE	MAE
0–2 mi	\$4.77	\$2.81
2–5 mi	\$6.79	\$4.31
5–10 mi	\$10.78	\$7.08
10+ mi	\$17.17	\$11.56

Borough	RMSE	MAE
Manhattan	\$10.54	\$6.58
Queens	\$9.16	\$4.98
Brooklyn	\$7.20	\$4.03
Staten Island	\$6.74	\$3.49
Bronx	\$5.70	\$3.29



Conclusão e Melhorias Futuras

- **O projeto demonstrou:**

- Pipeline Big Data end-to-end reproduzível em Docker
- Spark SQL para ETL/EDA em escala de 100M+ linhas
- Split temporal correto evita data leakage em séries temporais
- Trade-offs reais entre modelos distribuídos (LR/DT) e locais (NN)
- Diagnóstico e correção de bugs de infraestrutura (versão JAR, permissões, OOM)

- **Melhorias futuras:**

- Expandir para o recorte completo Jan/2022–Ago/2023 com hardware 16GB+
- Dados externos: clima NYC, eventos, greves de transporte
- Treino distribuído da NN